

1. Wstęp

Celem niniejszego projektu było stworzenie zbioru danych (datasetu) na platformie Roboflow oraz wykorzystanie go do wytrenowania sztucznej inteligencji (AI) do rozpoznawania trzech rodzajów liści: brzozy, kasztanowca i klonu. Projekt ten miał na celu zbadanie możliwości automatyzacji identyfikacji gatunków drzew na podstawie zdjęć liści, co może mieć szerokie zastosowanie w dziedzinie botaniki, ochrony środowiska oraz edukacji. Wytrenowany model AI, opracowany przy użyciu zasobów Google Colab, potrafi analizować obrazy liści i precyzyjnie określać ich rodzaj, co stanowi znaczący krok w kierunku rozwoju narzędzi wspierających pracę naukowców i entuzjastów przyrody.

2. Dataset

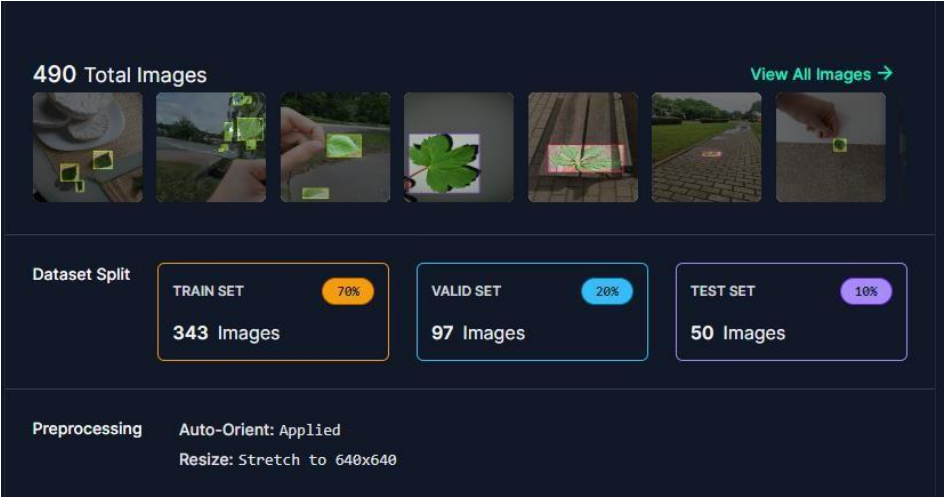
Stworzony zbiór danych składa się z 490 zdjęć liści trzech gatunków: brzozy, kasztanowca i klonu. Został on podzielony na trzy części:

Zbiór treningowy: 343 zdjęcia (70%),

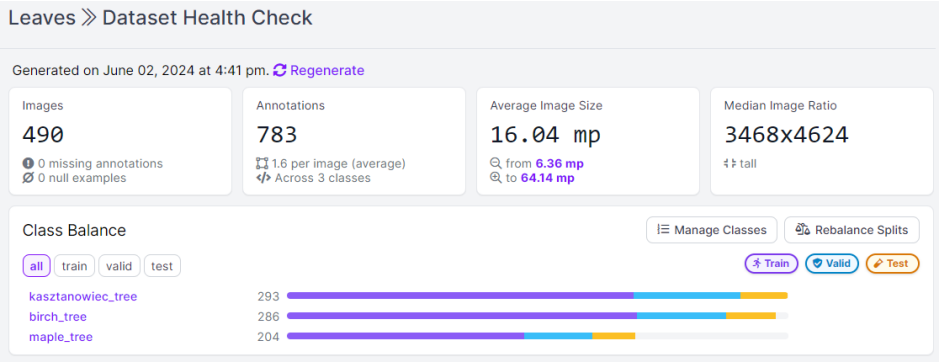
Zbiór walidacyjny: 97 zdjęć (20%),

Zbiór testowy: 50 zdjęć (10%).


Podział ten pozwolił na skuteczne wytrenowanie i ocenę modelu AI, który teraz potrafi precyzyjnie rozpoznawać rodzaje liści na podstawie zdjęć.



Rysunek 1 Dataset



Rysunek 2 Stan datasetu



Rysunek 3 Wykres współczynnika proporcji datasetu


3. Przygotowanie i trening modelu YOLO

W celu przygotowania i treningu modelu YOLO wykonano następujące kroki:


1. Instalacja bibliotek:

Zainstalowano bibliotekę ultralytics, zawierającą implementację modelu YOLO.

Zainstalowano bibliotekę roboflow, umożliwiającą pobranie datasetu z platformy Roboflow.




Rysunek 4 Instalacja ultralytics



Rysunek 5 Instalacja roboflow

2. Importowanie i konfiguracja YOLO:

Zaimportowano klasę YOLO z biblioteki ultralytics oraz sprawdzono zgodność środowiska.



Rysunek 6 Import YOLO oraz biblioteki

Potwierdzono poprawną konfigurację środowiska, w tym wersję YOLO, Pythona, Torch oraz dostępne zasoby obliczeniowe (GPU Tesla T4).

3. Pobieranie datasetu z Roboflow

Zaimportowano klasę Roboflow i uwierzytelniono się za pomocą klucza API.

Pobranie projektu z Roboflow, zawierającego zdjęcia liści trzech gatunków drzew (brzoza, kasztanowiec, klon), oraz przygotowanie go do użycia z YOLOv8.

```
from roboflow import Roboflow
rf = Roboflow(api_key="8UkfxsGPMHGHnQWgsnH0")
project = rf.workspace("leaves-zxysy").project("leaves-hkd1x")
version = project.version(1)
dataset = version.download("yolov8")

[7] !yolo train model=yolov8n.pt data='/content/Leaves-1/data.yaml' epochs=50 imgsz=640 device=0
```

Rysunek 7 Import datasetu liści z roboflow oraz trening modelu

Podczas treningu modelu YOLO wykorzystano 50 epok, co pozwoliło na skuteczne nauczenie się rozpoznawania różnych rodzajów liści z wysoką dokładnością. Proces ten odbył się na platformie Google Colab, co umożliwiło wykorzystanie zaawansowanych zasobów obliczeniowych.

Ten sam proces odbył się kolejne 2 razy dla wersji yolo8m.pt oraz yolo8x.pt w celu porównania wykresów i wytycznych tych 3 modeli, które będą pokazane w późniejszym etapie.

4. Przykładowe testy działania wytrenowanego modelu.


Przykład użycia wytrenowanego modelu będzie ukazany na 3 zdjęciach 3 rodzajów liści, zdjęcia te są losowe wzięte z google grafika.

```
[8] !yolo predict model=/content/runs/detect/train2/weights/best.pt source='https://www.tapeciarnia.pl/tapety/normalne/tapeta-liscie-kasztanowca-w-zblizeniu.jpg'


[11] !yolo predict model=/content/runs/detect/train2/weights/best.pt source='https://www.spirulina.pl/wp-content/uploads/2022/11/Lisciebrzozy.jpg'

!yolo predict model=/content/runs/detect/train2/weights/best.pt source='http://s3.eu-central-1.amazonaws.com/pressland-cms/cache/article_show_cover_1_1/ge/15976201-liscie-klonu.jpeg'
```

Rysunek 8 Import trzech różnych zdjęć ze stron internetowych



Rysunek 5 Działanie modelu na zdjęciu liści brzozy



Rysunek 10 Działanie modelu na zdjęciu liści klonu




Rysunek 11 Działanie modelu na zdjęciu liści kasztanowca


Jak widać na załączonych zdjęciach, model został wytrenowany i działa prawidłowo.

5. Porównanie Modelów YoloX, YoloM oraz YoloN.


Confusion matrix dla Yolo M



Confusion matrix dla YOLO N



Confusion matrix dla YOLO X



Analiza tych modeli dla Confusion matrix:

Ogólne obserwacje:

- Macierze pomyłek pokazują przewidywane względem rzeczywistych klasyfikacji dla czterech kategorii: brzoza, kasztanowiec, klon i tło.
- Elementy na przekątnej reprezentują poprawne przewidywania, podczas gdy elementy poza przekątną wskazują błędne klasyfikacje.

Szczegółowe porównanie:

1. YOLO M:

- Brzoza: 46 poprawnych, 1 błędnie sklasyfikowana jako kasztanowiec, 5 jako tło.
- Kasztanowiec: 51 poprawnych, 1 błędnie sklasyfikowana jako klon, 11 jako tło.

- Klon: 36 poprawnych, 1 błędnie sklasyfikowana jako kasztanowiec, 4 jako tło.
- Tło: 19 poprawnych, 10 błędnie sklasyfikowana jako kasztanowiec, 2 jako klon.

2. YOLO N:

- Brzoza: 49 poprawnych, 3 błędnie sklasyfikowana jako tło.
- Kasztanowiec: 52 poprawnych, 3 błędnie sklasyfikowana jako tło.
- Klon: 36 poprawnych, 2 błędnie sklasyfikowana jako tło.
- Tło: 20 poprawnych, 10 błędnie sklasyfikowana jako kasztanowiec, 4 jako klon.


3. YOLO X:

- Brzoza: 47 poprawnych, 2 błędnie sklasyfikowana jako klon, 3 jako tło.
- Kasztanowiec: 53 poprawnych, 1 błędnie sklasyfikowana jako klon, 8 jako tło.
- Klon: 36 poprawnych, 1 błędnie sklasyfikowana jako kasztanowiec, 4 jako tło.
- Tło: 27 poprawnych, 9 błędnie sklasyfikowana jako kasztanowiec, 4 jako klon.


Wniosek:

- **Najlepszy Ogólny Model:** YOLO N pokazuje zrównoważoną wydajność z wysoką dokładnością i mniejszą liczbą błędnych klasyfikacji w większości kategorii.
- **Wysoka Specyficzność dla Tła:** YOLO X ma najwięcej poprawnych identyfikacji tła, ale ma więcej błędnych klasyfikacji w innych kategoriach.
- **Obszary do Poprawy:** Każdy model może poprawić się w minimalizowaniu błędnych klasyfikacji, szczególnie dla kategorii tła.


F1 CURVE DLA YOLO M



F1 CURVE DLA YOLO N



F1 CURVE DLA YOLO X



Analiza tych modeli dla F1 CURVE:

YOLO M:

- Ogólny wynik F1: 0.87 przy ufności 0.637
- Wydajność dla poszczególnych klas:
 - Birch_tree: Najwyższy wynik F1 około 0.85
 - Kasztanowiec_tree: Podobnie wysoka wydajność około 0.85
 - Maple_tree: Nieco niższa, około 0.8

YOLO N:

- Ogólny wynik F1: 0.88 przy ufności 0.442
- Wydajność dla poszczególnych klas:
 - Birch_tree: Wysoki wynik F1, nieco powyżej 0.85
 - Kasztanowiec_tree: Blisko 0.9, najlepsza wydajność wśród klas
 - Maple_tree: Nieco lepiej niż YOLO M, około 0.85

YOLO X:

- Ogólny wynik F1: 0.87 przy ufności 0.636
- Wydajność dla poszczególnych klas:
 - Birch_tree: Konsekwentnie powyżej 0.8, nieco lepiej niż YOLO M
 - Kasztanowiec_tree: Blisko 0.9, podobnie jak YOLO N
 - Maple_tree: Nieco niższa niż inne klasy, ale stabilna

Porównanie i Podsumowanie:


- **Ogólna Wydajność:**
 - YOLO N ma najwyższy ogólny wynik F1 wynoszący 0.88.
 - YOLO M i YOLO X mają ten sam ogólny wynik F1 wynoszący 0.87, ale przy różnych poziomach ufności.
- **Wydajność dla Klas:**
 - **Kasztanowiec_tree:** YOLO N ma najlepszą wydajność, zaraz za nim jest YOLO X, a potem YOLO M.
 - **Maple_tree:** YOLO N jest nieco lepszy niż pozostałe modele.
 - **Birch_tree:** Wydajność jest stosunkowo podobna we wszystkich modelach, z lekką przewagą YOLO N.

Wniosek:


YOLO N wydaje się być najlepszym modelem spośród trzech, z najwyższym ogólnym wynikiem F1 i mocną wydajnością we wszystkich klasach, szczególnie przy niższym poziomie ufności (0.442). YOLO M i YOLO X mają podobne ogólne wyniki F1, ale YOLO X może być nieco lepszy ze względu na swoją stabilność w różnych klasach.

Dlatego na podstawie dostarczonych wykresów krzywych F1-Confidence, YOLO N jest najlepiej działającym modelem.


P CURVE DLA YOLO M



P CURVE DLA YOLO N



P CURVE DLA YOLO X



Analiza tych modeli dla P CURVE:

YOLO M:

- Wartość precyzji dla wszystkich klas wynosi 0.889.
- Wykres pokazuje, że model ma dobrą precyzję dla wszystkich trzech klas, przy czym klasa kasztanowca ma najwyższą precyzję w stosunku do pewności.
- Model ma tendencję do utrzymywania wysokiej precyzji w zakresie pewności od 0.5 do 1.0.

YOLO N:

- Wartość precyzji dla wszystkich klas wynosi 0.958.
- Wykres pokazuje, że YOLO N ma wyższą precyzję niż YOLO M dla wszystkich klas.
- Kasztanowiec ponownie ma najwyższą precyzję, a model ogólnie utrzymuje wyższą precyzję w całym zakresie pewności, szczególnie w porównaniu do YOLO M.

YOLO X:

- Wartość precyzji dla wszystkich klas wynosi 0.834.
- Wykres pokazuje, że YOLO X ma najniższą precyzję w porównaniu do YOLO M i YOLO N.
- Chociaż model nadal utrzymuje względnie wysoką precyzję, jest on nieco mniej stabilny w zakresie pewności od 0.5 do 1.0 w porównaniu do innych modeli.

Podsumowanie:

- **Najlepszy model:** YOLO N (najwyższa precyzja dla wszystkich klas, wartość precyzji 0.958)
- **Model średni:** YOLO M (dobra precyzja, ale niższa od YOLO N, wartość precyzji 0.889)
- **Najgorszy model:** YOLO X (najniższa precyzja, wartość precyzji 0.834)

Wnioski:

YOLO N jest najlepszym modelem z trzech analizowanych, oferującym najwyższą precyzję i stabilność w całym zakresie pewności. YOLO M jest nieco gorszy, ale nadal wykazuje dobrą precyzję. YOLO X, choć najmniej wydajny z trzech, nadal osiąga względnie wysoką precyzję, ale jest mniej stabilny i ma większe wahania w wynikach.

Ogólne Podsumowanie:

Najlepszy Ogólny Model: YOLO N wydaje się być najlepszym modelem z najwyższym ogólnym wynikiem F1 i mocną wydajnością we wszystkich klasach, szczególnie przy niższym poziomie ufności (0.442). Model wykazuje zrównoważoną wydajność z wysoką dokładnością i mniejszą liczbą błędnych klasyfikacji w większości kategorii.

YOLO N jest najlepszym modelem, oferującym najwyższą precyzję, stabilność oraz zrównoważoną wydajność. **YOLO M** i **YOLO X** są zbliżone pod względem ogólnych wyników, ale YOLO X może mieć przewagę ze względu na swoją stabilność. Wszystkie modele mają potencjał do poprawy, szczególnie w minimalizowaniu błędnych klasyfikacji, zwłaszcza w identyfikacji tła.